

ResDeepSurv: A Survival Model for Deep Neural Networks Based on Residual Blocks and Self-attention Mechanism

7.21

Contents

1. *Abstract*

2. *Introduction*

3. *Problem Definition*

4. *Model Architecture*

5. *Experiment*

6. *Conclusion*

Abstract

Cox PH의 선형성·feature engineering 한계를 극복하기 위해
Residual Block + Self-Attention 기반 딥러닝(ResDeepSurv)을 제안,
선형·비선형 위험함수 모두에서 기존 생존분석 모델 대비
동등 이상의 C-index 성능을 다수의 임상 데이터셋으로 검증.

Introduction

생존분석은 사건 발생 시점 예측 및 공변량-위험률 관계 파악을 위한 의학 분야 핵심 방법론

Related Work & Common Limitation

CPH 기반 딥러닝 모델(PH 가정 유지) 비선형 포착 가능하나 비례위험 가정 의존

- DeepSurv — CPH의 비선형 확장, 비례위험 가정 유지
- Feed-forward NN + CPH (David et al.) — CPH와 결합한 신경망, 비례위험 가정 유지

PH 가정에서 자유로운 모델 Cox 대비 일관된 성능 우월성 미입증

- RSF — 트리 기반, 비례위험 가정 없음
- SVM — 비례위험 가정 없음

<Contributions of the Proposed Model>

1. Residual Block + Self-Attention으로 생존시간 분포를 직접 모델링하고, 기본 분포 가정 없이 공변량-결과 간 복잡한 관계를 포착. Cox partial likelihood를 loss로 활용해 딥러닝의 비선형 표현력 + Cox의 해석력을 동시에 확보.
2. 다수의 공개 임상 데이터셋에서 기존 생존분석 모델 대비 동등 이상의 예측 성능 달성.
3. 치료 추천 시스템에 통합하여 실제 생존 데이터에서의 임상적 유용성 검증.

Problem Definition

생존 데이터는 세 가지 요소로 구성

X : 환자 공변량 행렬 ($N \times m$)

Y : 관측 시간 벡터 — 사건 발생 시 T_i , 중도절단 시 C_i


E : 사건 발생 여부 ($e_i=1$: 사건 발생, $e_i=0$: 중도절단)

$$X = \begin{bmatrix} x_1 \\ \vdots \\ x_N \end{bmatrix} = \begin{bmatrix} x_{11} & \cdots & a_{1m} \\ \vdots & \ddots & \vdots \\ a_{N1} & \cdots & a_{Nm} \end{bmatrix}.$$


$$Y = [y_1, y_2, y_3, \dots, y_N]$$

$$E = [e_1, e_2, e_3, \dots, e_N].$$

Model Architecture



[Survival Data] → [Data Preprocessing] → [Model] → [Output]



Residual Block과 Self-Attention의 결합으로 이루어짐

모델로 하여금 공변량과 생존시간 간 선형/비선형 관계를 모두 포착할 수 있도록 도와줌

2.4.1 Residual Units

▷ 기존 딥러닝에서의 구조(아래 논문에 따르면, 이미지 인식 태스크에 다음과 같은 구조를 적용)

[Conv 3×3] → [BN] → [ReLU] → [Conv 3×3] → [BN] → [⊕] → [ReLU]

출처: He, K., Zhang, X., Ren, S., & Sun, J. (2016). "Deep Residual Learning for Image Recognition" CVPR 2016


▷ 현 논문의 ResDeepSurv모델에서의 구조:

[Linear] → [BN] → [ReLU] → [Linear] → [BN] → [⊕]

ResDeepSurv의 Residual Unit은 두 개의 Linear Layer, Batch Normalization Layer, 활성화 함수로 구성되며,

기존 ResNet의 Convolution Kernel 대신 이 구조를 사용하여 특징을 변환한다.

특징 간 비선형 관계를 학습하고 특징 벡터의 서로 다른 차원 간 교차 결합을 수행하며, 결과적으로 모델은 더 많은 비선형 및 결합적 특징 정보를 얻어 표현력이 향상



2.4.2 Self-attention Mechanism Layer

ResDeepSurv는 특징의 중요도와 가중치를 포착하기 위해 self-attention mechanism을 도입한다.

Attention mechanism은 입력 특징에 의해 각 특징의 attention score를 동적으로 계산하며, 특징마다 목표 변수 예측에 기여하는 정도가 다를 수 있다. 특징의 중요도를 학습함으로써 핵심 특징 간 상호작용 포착 능력이 향상되고, 예측 정확도가 높아진다.


이를 수식으로 표현하면 다음과 같다.

$$A = \text{softmax}(X_I X_I^T) \quad (14)$$

$$X_O = A X_I \quad (15)$$

A 는 softmax로 정규화된 attention score이며 각 가중치의 합은 1, 범위는 0~1이다.

입력 특징 간 유사도 행렬 A 로 각 특징의 중요도를 계산
 $XO=AXI$ 로 가중 합산해 핵심 특징 간 상호작용을 자동 포착하는 메커니즘.



Section 3.1 Experimental Setup

ResDeepSurv는 CPH, RSF, DeepSurv, Deep Cox Mixture(DCM), DR, DeepHit
6개의 기존 생존분석 모델과 비교

분할: Train:Test= 80:20

PreProcessing: 결측값이 있는 환자를 제거, 범주형 변수는 레이블 인코딩으로 변환

HyperParameter: C-index를 최대화하는 방향으로 5-fold Cross Validation을 통해 선택
신경망 모델의 95% 신뢰구간은 Bootstrap Sampling으로 추정

Evaluation Metrics: C-index & IBS

RSF

Ishwaran H, Kogalur UB, Blackstone EH, Lauer MS (2008) Random survival forests.
The Annals of Applied Statistics, 2(3):841–860. DOI: 10.1214/08-AOAS169

We introduce random survival forests, a random forests method for the analysis of right-censored survival data. New survival splitting rules for growing survival trees are introduced, as is a new missing data algorithm for imputing missing data. A conservation-of-events principle for survival forests is

2. Random survival forests algorithm. We begin with a high-level description of the algorithm. Specific details follow:

1. Draw B bootstrap samples from the original data. Note that each bootstrap sample excludes on average 37% of the data, called out-of-bag data (OOB data).
2. Grow a survival tree for each bootstrap sample. At each node of the tree, randomly select p candidate variables. The node is split using the candidate variable that maximizes survival difference between daughter nodes.
3. Grow the tree to full size under the constraint that a terminal node should have no less than $d_0 > 0$ unique deaths.
4. Calculate a CHF for each tree. Average to obtain the ensemble CHF.
5. Using OOB data, calculate prediction error for the ensemble CHF.

부트스트랩 샘플로 키운 B개의 생존나무 앙상블로, Cox PH의 선형성·비례위험 가정 없이 우측중도절단 생존 데이터를 분석하는 비모수적 방법론.


DeepSurv

Katzman JL, Shaham U, Cloninger A, Bates J, Jiang T, Kluger Y (2018) DeepSurv: personalized treatment recommender system using a Cox proportional hazards deep neural network. BMC Medical Research Methodology, 18:24.

Methods: We introduce DeepSurv, a Cox proportional hazards deep neural network and state-of-the-art survival method for modeling interactions between a patient's covariates and treatment effectiveness in order to provide personalized treatment recommendations.

DeepSurv

DeepSurv is a deep feed-forward neural network which predicts the effects of a patient's covariates on their hazard rate parameterized by the weights of the network θ .



Cox PH의 선형 log-risk 가정을 딥러닝으로 대체해 환자 공변량과 위험률의 비선형 관계를 습하고, 개인별 치료 추천까지 제공하는 feed-forward 신경망.

Deep Cox Mixture(DCM)

Chirag N, Steve Y, Negar R, et al (2021) Deep cox mixtures for survival regression.

regression models being amongst the most commonly employed models. We describe a new approach for survival analysis regression models, based on learning mixtures of Cox regressions to model individual survival distributions. We propose an approximation to the

Cox 회귀의 혼합 모델을 학습하여 개별 생존 분포를 모델링

In this paper we propose, ‘**Deep Cox Mixtures**’ for survival analysis, which generalizes the proportional hazards assumption via a mixture model, by assuming that there are latent groups and within each, the proportional hazards assumption holds. Our approach allows the hazard ratio in each latent group, as well as the latent group membership, to be flexibly modeled by a deep neural network, allowing us to take advantage of the recent improvements in neural network modeling of patient data.

비례 위험 가정의 강한 제약 없이 잠재 그룹 내에서 비례 위험 가정이
성립하도록 혼합 모델을 구성

DR BingZhong J, Tao Z, Zixian W et al (2019) A deep survival analysis method based on ranking. Artif Intell Med 98:1–9

(Deep survival analysis based on Ranking)

DR introduces a new loss function that combines the extended mean square error loss with paired sorting loss

reported. In this paper, we propose an innovative loss function that is defined as the sum of an extended mean squared error loss and a pairwise ranking loss based on ranking information on survival data. We apply this loss function to optimize a deep feed-forward neural network (RankDeepSurv), which can be used to model survival data. We demonstrate that the performance of our model, RankDeepSurv, is superior to that of other state-of-the-art survival models based on an analysis of 4 public medical clinical datasets.

Deephit

. Lee C, Zame W, Yoon J, et al (2018) Deephit: A deep learning approach to survival analysis with competing risks. In: AAAI Conf Artif Intell

are often violated. This paper proposes a very different approach to survival analysis, *DeepHit*, that uses a deep neural network to learn the distribution of survival times directly. DeepHit makes no assumptions about the underlying stochastic process and allows for the possibility that the relationship between covariates and risk(s) changes over time. Most importantly, DeepHit smoothly handles *competing risks*; i.e. settings in which there is more than one possible event of interest. Comparisons with previous models on the basis of real and synthetic datasets demonstrate that DeepHit achieves large and statistically significant performance improvements over previous state-of-the-art methods.

환자의 공변량에서 모든 사건에 공통된 위험 패턴을 먼저 추출하고, 이를 각 사건별 서브네트워크에 넘겨 "이 환자가 시점 t에 사건 k로 사망할 확률"을 동시에 추정하는 구조.

Model Description

Our goal is to train the network to learn $\hat{P}$, the estimate of the joint distribution of the first hitting time and competing events. As illustrated in Figure 2, DeepHit is a multi-task network (Collobert and Weston 2008) which consists of a shared sub-network and K cause-specific sub-networks. Our architecture, differs from that of conventional multi-task network in two ways. First, we utilize a single softmax layer as the output layer of DeepHit in order to ensure that the network learns the *joint distribution* of K competing events not the *marginal distributions* of each event. Second, we maintain a residual connection (He et al. 2016) from the input covariates into the input of each cause-specific sub-network.





Figure 2: The architecture of DeepHit with two competing events.


Section 3.2 Simulated Datasets

정답을 알고 있는 데이터에서의 성능 검증,
모델이 실제로 올바른 위험 구조를 학습했는지 직접 검증 가능


C index(Y축) Results



CPH가 잘 처리할 수 있는 문제에서도 Resdeepsurv가 가장 높은 성능을 보임




CPH와의 격차가 벌어짐




10개 공변량 중 2개만 위험함수와 관련,
관련없는 noise 섞여 있어도 진짜 중요한 변수를
정확히 찾아내는 ResDeepSurv의 강건함

Section 3.3 Real Datasets







ResDeepsurv의 성능이
METABRIC과 Rotterdam & GBSG에서 1위, WHAS에서는 RSF에 근소하
게 밀려 2위, SUPPORT에서는 DR에 근소하게 밀려 2위를 기록



C index Results

Section 3.3 Real Datasets



METABRIC, SUPPORT,
Rotterdam & GBSG 데이터셋에서
1위를 기록


IBS Results
(Y축= IBS 값)
Y축값이 낮을수록 좋음

Section 3.4 Exploring the Effect on Treatment Recommendations

Rotterdam Tumor Bank 데이터로 학습한 모델을 GBSG 데이터에 적용하여 치료 추천의 효과를 검증

ResDeepSurv의 추천을 따른 환자 그룹은 따르지 않은 그룹보다 중앙 생존시간이 31.5개월에서 39.2개월로 7.7개월 증가

Fig. 5 Kaplan–Meier survival curves for patients receiving recommendations or not. **a** represents the survival curves of patients who received treatment consistent with method recommendations. **b** represents the survival curves of patients who did not receive any form of treatment



RSF는 동일한 실험에서 유의미한 생존 차이를 만들지 못함

ResDeepSurv가 단순한 예측을 넘어 임상적으로 유용한
개인화 치료 추천 도구로서의 가능성을 증명

Section 4 Conclusion

- 본 연구는 Residual Block과 Self-Attention 기반의 딥러닝 모델인 ResDeepSurv를 제안함
- ResDeepSurv는 신경망을 통해 생존시간 분포를 직접 모델링하고 비선형 관계를 효과적으로 포착함으로써 이를 해결
- 다양한 데이터셋 실험을 통해 기존 방법 대비 높은 예측 정확도를 달성했으며, 개인화 치료 추천 시스템으로의 확장 가능성도 검증
- 다만 본 연구에서 사용한 데이터셋은 주로 유방암·심혈관 질환에 한정되어 있어,
다양한 의학 분야로의 일반화 가능성과 고차원 유전체 데이터 등 대규모 입력에서의 강건성은 추가 검증이 필요하다.