

Interval-Censored Survival Analysis with Neural Networks

2026.8.4

Chaewon Park

What is **Interval Censoring**?

정의: 관심 확률변수가 정확히 관측되지 않고,
어떤 구간 안에 있다는 것만 알 수 있는 불완전 데이터 구조

수식: $L < T \leq R$ (T: 실제 사건 발생 시점, 미관측)

발생 원인: 주기적 검진(periodic follow-up) →

직전 검진: 사건 미발생 / 다음 검진: 사건 발생 확인 → 정확한 시점 모름, 구간만 앎

실제 예시: 임상시험에서 질병 상태 변화 시점 ,

AIDS 발병 시점 (혈액검사가 주기적으로만 가능) ,

HIV 감염 시점 (마지막 음성 ~ 첫 양성 검사 사이)

Neural interval-censored survival regression with feature selection

Carlos García Meixide^{1,2} | Marcos Matabuena³ | Louis Abraham⁴ | Michael R. Kosorok⁵

기반 모델: AFT
DNN 구조: Sparse NN(LassoNet)
변수 선택: Stability Selection
실제 데이터: 1형 당뇨병

Meixide et al. (2024)
García Meixide, C., Matabuena, M., Abraham, L., & Kosorok, M. R. (2024).
Neural interval-censored survival regression with feature selection. Statistical
Analysis and Data Mining: The ASA Data Science Journal, 17, e11704.

Neural network on interval-censored data with application to the prediction of Alzheimer’s disease

Tao Sun^{1,2} | Ying Ding²

기반 모델: PH(Cox)
DNN 구조: BPNet+ NN
변수 선택: GWAS Score Test
실제 데이터: 알츠하이머 ADNI

Sun & Ding (2023)
Sun, T., & Ding, Y. (2023). Neural network on interval-censored data with application
to the prediction of Alzheimer's disease. Biometrics, 79(3), 2677–2690.

모두 불확실성 정량화 x

① Meixide et al. (2024) $\phi(t) = \log(t)$.
AFT $\log T = r_{\theta, W}(Z) + \varepsilon$, $r_{\theta, W} \in \mathcal{R}$ with $\varepsilon \sim \mathcal{N}(0, \sigma^2)$

$G(t|z) = F(\phi(t) - r(z))$ AFT model

Interval-Censored 우도

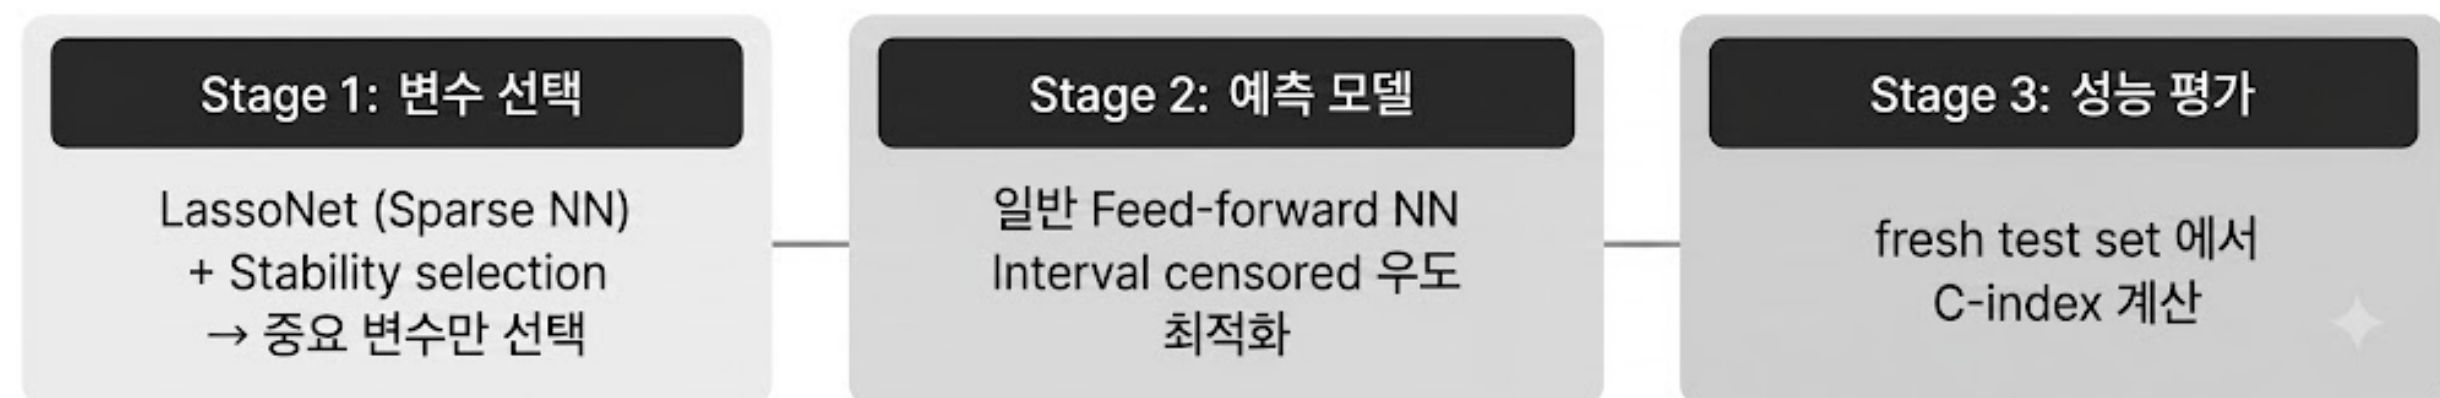
$$l_n(\sigma, r) = \sum_{i=1}^n \left\{ \delta_{1i} \log F\left(\frac{\log U_i - r(Z_i)}{\sigma}\right) + \delta_{2i} \log \left[F\left(\frac{\log V_i - r(Z_i)}{\sigma}\right) - F\left(\frac{\log U_i - r(Z_i)}{\sigma}\right) \right] + \delta_{3i} \log \left[1 - F\left(\frac{\log V_i - r(Z_i)}{\sigma}\right) \right] \right\},$$

$\delta_1 = 1$ (Left Censoring): $F((\log U_i - r(Z_i))/\sigma)$

$\delta_2 = 1$ (Interval Censoring):
 $F((\log V_i - r(Z_i))/\sigma) - F((\log U_i - r(Z_i))/\sigma)$

$\delta_3 = 1$ (Right Censoring): $1 - F((\log V_i - r(Z_i))/\sigma)$

3 Step Pipeline



변수 선택: LassoNet + Stability Selection

LassoNet: Sparse NN

optimization problem

$$\begin{aligned} & \underset{\sigma, \theta, W}{\text{minimize}} && L(\sigma, \theta, W) := -l_n(\sigma, \theta, W) + \lambda \|\theta\|_1 \\ & \text{subject to} && \|W_j^1\|_\infty \leq M|\theta_j|, j = 1, \dots, d, \end{aligned}$$

Stability Selection

Motivation: DNN에서 CV가 불안정
(매 실행 시 다른 변수 선택)

- 데이터를 반복적으로 subsampling (without replacement)
 - 각 subsample마다 다양한 λ 값으로 변수 선택 적용
 - 각 변수의 selection probability 집계
 - 임계값 π_{thr} 이상인 변수만 최종 선택
- (Simulation: 100 subsamples $\times$ 50 values of λ)

Simulation Settings

공통 설정 : $F =$ 표준정규 CDF, $\varphi(t) = \log(t) \rightarrow \log T = r\theta, W(Z) + \varepsilon, \varepsilon \sim N(0, \sigma^2=0.25)$
500 replicas $\times n \in \{500, 1000, 2000\}$, $p = 100$ 개 공변량, 평가 : C-index, R^2 , $\hat{\sigma}$ 수렴

EX1) Nonlinear

$$\log T = X_1 + X_1^2 - 0.5(X_2 + X_2^2) + 0.5(X_3 + X_3^2) + 1 + \varepsilon,$$

- $X_1, X_2, X_3 \sim N(0, 1)$, 나머지 97개는 노이즈
- 교호작용·이차항 포함 $\rightarrow$ 명확한 비선형 구조
- 독립 공분산 행렬 (identity)
- LogNormal AFT 대비 비선형 포착 능력 테스트

EX2)

$$\log T = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 \\ + \beta_4 X_1 X_3 + \beta_5 \log(X_2^2 + 1) + \varepsilon,$$

- $\beta_0=-2, \beta_1=0.5, \beta_2=-0.7, \beta_3=0.8, \beta_4=0.6, \beta_5=-0.3, \sigma=0.5$
- AR(1) 공분산 구조 ($\rho=0.3$)
선형에 가까운 설정

Simulation Results (Meixide(left) & LogNormal AFT(Right))

시뮬레이션 결과 (B=500, n=500/1000/2000)

Method	n=500	n=1000	n=2000	σ^2 수렴
Meixide (Example 1)	0.812	0.817	0.820	0.473
LogNormal AFT	0.678	0.681	0.685	1.843
Meixide (Example 2)	0.811	0.816	0.819	0.487
LogNormal AFT	0.814	0.814	0.815	0.932

Example 1: 비선형 설정에서 제안 모델이 40% 높은 예측력, $\hat{\sigma}$ 참값 수렴 vs 경쟁 모델 발산

Example 2: 선형 유사 설정에서 두 모델 comparable, 단 $\hat{\sigma}$ 수렴은 제안 모델만 달성

실제 데이터 : T1D Exchange (당뇨 신장 합병증)

n: 5,971 명 | 변수 17 개 → 선택 5 개

선택 : HbA1c, 인슐린 용량 , ACE 억제제 복용 여부 , 인슐린 주사 횟수 , 섬세포 이식 여부

결과 : NN 모델 C-index 0.65 vs 전통 AFT 0.54 → 20% 향상

Conclusion

Interval censoring + AFT + DNN을 최초로 결합하여,
비선형 설정에서 LogNormal AFT 대비 40% 높은 예측력을 달성함
 $\hat{\sigma}$ 이 참값에 수렴함을 보였으며,
LassoNet 기반 변수 선택으로 T1D 당뇨 데이터에서 17개 중 5개 핵심 변수를 안정적으로 선택

<한계>

- ① 불확실성 정량화 없음
 - credible interval 제공 불가
 - DeepGP-AFT가 이미 해결한 부분
- ② 노이즈 환경에서 변수 선택 불안정
 - DNN 초기값 랜덤성으로 인한 한계
 - Stability selection으로 완화했지만 완전 해결 아님
- ③ 함수형 예측변수 미지원
 - 의료 이미지, 웨어러블 신호 등 처리 불가

2

Sun & Ding (2023)

Novel neural network method for interval-censored data

핵심 기여 : 두 개의 신경망을 동시에 학습

L_i 와 R_i 모두 활용 $\leftarrow$ Right censoring 과의 핵심 차이

일반 NN: $g(Z_i; \theta)$ 추정

공변량 Z_i 를 입력,

Risk index 출력,

L_1 정규화로 과적합 방지

BPNet: $\Lambda(L_i), \Lambda(R_i)$ 추정

Bernstein polynomial 기반,

단조증가 보장,

L_i 또는 R_i 를 입력

2

Sun & Ding (2023)

<GWAS & Simulation Results>

GWAS 파이프라인 (알츠하이머 예측)

Sieve 추정

Bernstein polynomial 로
 $\Lambda(t)$ 추정
(Section 3)

Score Test

SNP 별 연관성 검정
계산 3 일
(vs Wald 14 일)

SNP 선택

p-value 임계값으로
71~1970 개 SNP
추출

NN-IC 예측

선택된 SNP +
임상변수로
예측 모델 구축

GWAS 주요 결과 GWAS로 검증하고 싶은 것: “수백만 개의 SNP(유전자 변이) 중에서 어떤 것이 알츠하이머 발병과 연관되어 있는가?”

APOE = Apolipoprotein E, 알츠하이머와 가장 강하게 연관된 유전자

"800만 SNP 중 AD 발병 시간과 유의하게 연관된 유전자 발견" : 기존 알려진 유전자 재확인

→ APOE 영역, CHRNA4, 방법론 타당성 검증

새로운 유전자 발견 → CDKN2AIP (세포 노화·증식 관련), 이 논문의 기여

NN-IC 구조

Do not consider left truncation

1> 모델 정의

$$\Lambda(t|\mathbf{Z}_i) = \Lambda(t)e^{g(\mathbf{Z}_i;\theta)} \quad \text{PH assumption}$$

$g(\mathbf{Z}_i;\theta)$ estimate various nonlinear structures of $g(\cdot)$

$\Lambda(t)$ unspecified baseline cumulative hazard function

2> Loss Function

$$\frac{1}{n} \sum_{i=1}^n \log[\exp\{-\Lambda(L_i)e^{g(\mathbf{Z}_i;\theta)}\} - \exp\{-\Lambda(R_i)e^{g(\mathbf{Z}_i;\theta)}\}]. \quad \Lambda(L_i), \Lambda(R_i) \text{ 동시 추정해야 함}$$

3>BPNet

NN-IC = 일반 NN ($g(\mathbf{Z}_i;\theta)$ 추정) + BPNet ($\Lambda(L_i), \Lambda(R_i)$ 추정)

$$o_i = f^{out}\left(\sum_{k=0}^{m_n} w_k a_k\right) = \sum_{k=0}^{m_n} w_k a_k = \sum_{k=0}^{m_n} w_k B_k(L_i, m_n, c, u), \quad 0 \leq w_0 \leq \dots \leq w_{m_n} \quad \text{단조증가 보장, 두 BPNet이 가중치 공유}$$

Simulation 설정

PH 모델 기반 ,Weibull 기저위험함수 ($\lambda=0.01, k=10$) ,200 회 반복, $n=1,000$ $p \in \{20, 50, 100, 500\}$,
right-censoring 50% , 비교 : NN-IC vs ICcforest vs ALASSO

5 가지 시나리오

$$\text{Scenario1 : } h(t|Z_i) = h_0(t) \exp \left(\sum_{j=1}^p \beta_j Z_{ij} \right), \quad (11)$$

$$\text{Scenario2 : } h(t|Z_i) = h_0(t) \exp \left(\sum_{j=1}^p \beta_j Z_{ij} + Z_{i1}^2 + Z_{i2}^2 \right), \quad (12)$$

$$\text{Scenario3 : } h(t|Z_i) = h_0(t) \exp \left(\sum_{j=1}^p \beta_j Z_{ij} + Z_{i3} Z_{i4} \right), \quad (13)$$

$$\begin{aligned} \text{Scenario4 : } h(t|Z_i) \\ = h_0(t) \exp \left(\sum_{j=1}^p \beta_j Z_{ij} + Z_{i1}^2 + Z_{i2}^2 + Z_{i3} Z_{i4} \right), \end{aligned} \quad (14)$$

$$\begin{aligned} \text{Scenario5 : } h(t|Z_i) \\ = h_0(t) \exp \left(\sum_{j=1}^p \beta_j Z_{ij} + I(Z_{i1} < -0.5 \cup Z_{i2} < -0.5) \right. \\ \left. - I(Z_{i1} \geq -0.5 \cap Z_{i2} \geq -0.5) + Z_{i3} Z_{i4} \right), \end{aligned} \quad (15)$$

Linear effects(scenario 1)

linear effects together with nonlinear effects (scenario 2)

with interactions (scenario 3)

with nonlinear and interaction effects (scenario 4)

with interaction and indicator effects (scenario 5)

Simulation 결과

시뮬레이션 : 평균제곱예측오차 ($\times 100$, 200 회 , Table 2)

	p=20	p=50	p=100	p=500
NN-IC / S1	0.7(0.3)	1.1(0.6)	1.9(1.7)	3.0(4.0)
ICforest / S1	0.7(0.3)	1.7(0.9)	2.9(1.5)	6.4(3.4)
ALASSO / S1	0.5(0.4)	1.0(0.8)	2.1(1.8)	8.0(3.5)
NN-IC / S2	0.8(0.8)	1.4(1.2)	1.8(1.4)	4.4(7.1)
ICforest / S2	1.0(0.4)	1.9(1.0)	3.0(1.5)	6.5(3.4)
ALASSO / S2	1.0(0.4)	1.4(0.9)	2.8(1.8)	8.2(3.4)
NN-IC / S3	0.8(0.4)	1.2(0.6)	1.8(1.4)	3.3(2.8)
ICforest / S3	0.9(0.4)	1.8(0.9)	3.0(1.5)	6.5(3.4)
ALASSO / S3	0.8(0.4)	1.3(0.9)	2.4(1.9)	7.7(3.4)
NN-IC / S4	0.8(0.3)	1.3(0.7)	2.0(1.6)	4.0(3.7)
ICforest / S4	1.2(0.4)	2.0(0.9)	3.1(1.5)	6.6(3.4)
ALASSO / S4	1.2(0.5)	1.6(0.9)	2.7(1.9)	7.9(3.3)
NN-IC / S5	0.7(0.3)	1.2(0.6)	1.8(1.3)	4.4(4.7)
ICforest / S5	0.9(0.4)	1.8(0.9)	2.9(1.5)	6.5(3.4)
ALASSO / S5	0.8(0.4)	1.3(0.8)	2.5(1.8)	8.3(3.4)

NN-IC는 전 시나리오(S1~S5)·전 차원 (p=20~500)에서 ICcforest, ALASSO 대비 일관되게 낮은 예측오차를 달성하며, p가 커질수록 경쟁 모델과의 격차가 더 벌어짐

Table 3 = 실제 데이터 (ADNI, 임상 적용)

(a) Internal validation (Data1, 5-fold CV)

→ IBS, p_out, d_out

→ Scenario 1~4 (p-value threshold 4가지)

(b) External validation (Data2)

→ IBS, p_out, d_out

→ Scenario 1~4

① SNP 수 증가할수록 NN-IC 성능 향상

IBS: 0.065(S1) → 0.040(S4) internal

0.084(S1) → 0.069(S4) external

② 고차원에서 icenReg, Bayesian, ALASSO 실패

S3, S4에서 행렬 계산 불가로 수렴 실패

③ NN-IC가 ICcforest 대비 일관되게 우수

External IBS: 0.069 vs 0.086

④ 고위험·저위험 Subgroup 식별

log-rank $p = 7.4 \times 10^{-5}$

ICcforest는 식별 불가

Conclusion

Interval censoring을 처리하면서 GWAS 전체를 활용한 최초의 AD 예측 연구

두 가지 핵심 기여

① GWAS

→ AD 발병 시간까지 반영한 최초 GWAS. Interval censoring + left truncation을 sieve 추정으로 처리

② NN-IC

→ BPNet으로 $\Lambda(t)$ 단조증가 보장. 시뮬레이션 + ADNI 모두에서 기존 방법 대비 우수

한계:

하이퍼파라미터 튜닝 필요 + Caucasian 한정 (다른 인종 적용 불가)

향후 연구

- 시간 변화 예측변수 추가 (인지 기능 점수 등)
- MRI 등 의료 이미지 특징 추출 후 통합
- Non-Caucasian 대상 별도 모델 개발